

Generalized Linear Mixed-Effects Model

Privação de sono

- ▶ Lembram-se do exercício que fizemos na aula anterior sobre privação de sono?
- ▶ Vários condutores de caminhão foram submetidos a apenas 3 horas de sono por noite durante várias noites consecutivas. Seu desempenho cognitivo (Reação) foi avaliado todos os dias usando o tempo médio de reação (em ms)
- ▶ O objetivo era saber se o tempo de reação varia com o número cumulativo de dias em privação de sono?

Privação de sono

- ▶ Usamos a library lmer e usando os dados sleepstudy:

```
> library(lme4)  
> data("sleepstudy")
```

Privação de sono

- ▶ Este conjunto de dados contém 3 variáveis (“*Reaction*”, “*Days*” e “*Subject*”). “*Reaction*” é o tempo de reação em ms, “*Days*” é o dia em que a medição foi realizada, contando a partir do primeiro dia sem privação de sono (Days=0). “*Subject*” é o número único de identificação de cada motorista

```
> colnames(sleepstudy)
```

```
[1] "Reaction" "Days"      "Subject"
```

Privação de sono

- ▶ Na aula passada fizemos um **Modelo Linear Misto**

```
> model <- lmer(Reaction ~ Days + (Days | Subject), sleepstudy)
> summary(model)
```

Fixed effects:

	Estimate	Std. Error	t value
(Intercept)	251.405	6.825	36.838
Days	10.467	1.546	6.771

tempo médio de reação no início: 251,4 ms

média aumento do tempo de reação devido à
privação de sono: 10,5ms/dia

Generalized Linear Mixed-Effects Model

- ▶ Mas, *lmer* é apenas uma maneira mais direta e simples de fazer um Modelo Linear Generalizado com Efeitos Mistos (Generalized Linear Mixed-Effects Model - GLMM)
- ▶ Um GLMM é um modelo estatístico que é usado para analisar dados com efeitos fixos e aleatórios. Estende o Modelo Linear Generalizado (GLM) incorporando os efeitos de um fator aleatório, o que permite a modelação de estruturas de dados complexas com múltiplos níveis de variabilidade, como aconteceu no estudo do sono.

Generalized Linear Mixed-Effects Model

- ▶ Num GLMM, a variável dependente pode ser uma variável contínua ou categórica, e o relacionamento entre a variável dependente e as variáveis independentes é modelado usando uma função de link como no GLM.
- ▶ Os efeitos fixos são as variáveis independentes de interesse primário, e os efeitos aleatórios são aqueles que não são diretamente de interesse, mas são incluídos para contabilizar o variabilidade nos dados. Em outras palavras, o GLMM é usado em situações onde as observações não são independentes (medidas repetidas)

Generalized Linear Mixed-Effects Model

- ▶ **lmer**: Linear Mixed Effects Model, é usado para variáveis dependentes contínuas
- ▶ **glmer**: Generalized Linear Mixed Effects Model, é usado para variáveis dependentes não contínuas, como variáveis binários, contagens, ordinais...

Generalized Linear Mixed-Effects Model

- ▶ Então se eu ajustar um modelo dos exemplo anterior para estudo do sono com glmer com a função de link “identidade” o que acontece?

```
> model <- lmer(Reaction ~ Days + (Days | Subject), sleepstudy)
> summary(model)
```

Fixed effects:

	Estimate	Std. Error	t value
(Intercept)	251.405	6.825	36.838
Days	10.467	1.546	6.771

```
> newmodel <- glmer(Reaction ~ Days + (Days | Subject), family= gaussian(link="identity"), data=sleepstudy)
```

Warning message:

In glmer(Reaction ~ Days + (Days | Subject), family = gaussian(link = "identity"), :
calling glmer() with family=gaussian (identity link) as a shortcut to lmer() is deprecated; please call lmer() directly

```
> summary(newmodel)
```

Fixed effects:

	Estimate	Std. Error	t value
(Intercept)	251.405	6.825	36.838
Days	10.467	1.546	6.771

Porque preciso do glmer se tenho o lmer?

- ▶ Exatamente para usar quando a variável dependente não é contínua, como por exemplo em situação em que a variável dependente representa uma contagem (regressão de Poisson) ou uma variável binária, 0 e 1 (regressão logística).
- ▶ Nesta situação já utilizamos o GLM em uma aulas passadas, quando aprendemos regressão logística e de Poisson, mas...
...e se temos contagens e medidas repetidas, por exemplo?
Nesse caso precisamos do GLMM.

Exemplo: pé diabético

- Suponha que estamos interessados em estudar o efeito de uma intervenção educativa num grupo de pacientes com diabetes tipo II. Temos informações sobre a presença ou ausência de úlcera de pé diabético tipo II (variável dependente binária) em 50 pacientes em dois momentos: no início do estudo (tempo=0) e após 1 ano de acompanhamento (tempo=1). Além disso, temos informações sobre a idade dos pacientes. O objetivo é avaliar se a intervenção educativa (intervenção=1) reduziu a presença de úlcera após 1 ano de acompanhamento, ajustando para idade.

Exemplo: pé diabético

```
> fit2 <- glmer(lesao ~ intervencao + idade + tempo +(tempolid), family = binomial(), data = diab2)
> summary(fit2)
```

Fixed effects:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.21617	1.94245	-0.626	0.531
intervencao	-0.77901	0.52016	-1.498	0.134
idade	0.01010	0.03127	0.323	0.747
tempo	-0.17839	0.75239	-0.237	0.813

```
> fixed_effects <- fixef(fit2)
```

```
> exp(fixed_effects)
```

(Intercept)	intervencao	idade	tempo
0.2963636	0.4588615	1.0101466	0.8366191